Infraestructura abierta de datos para una emergencia: recolección, flujo reproducible y gobernanza

Julián Maya
Universidad San Francisco de Quito (USFQ) · USFQ Galápagos
jamaya@usfq.edu.ec

Issues #36–#51 y #76 · repositorio mayait/sosgalapagos-datos
4 de noviembre de 2026

RESUMEN

Las inundaciones del 30–31 de octubre de 2026 en Santa Cruz y San Cristóbal (Galápagos) obligaron a montar en pocos días una infraestructura de datos para la respuesta: capas geográficas, lluvia medida casi en tiempo real, modelos hidrológicos y estudios técnicos publicados en la web. Este informe, en formato de *data paper*, describe esa infraestructura y las reglas que la gobiernan. Tiene cinco componentes. (1) Un recolector consulta cada 5 minutos las estaciones de IERSE, USFQ GSC, INAMHI y otras fuentes. Guarda todo en una base SQLite con las horas en UTC, y un puente desde Ecuador trae las estaciones de IERSE, que no responden desde el servidor. (2) Los datos crudos se guardan tal como llegan, un archivo por día, y nunca se modifican: hasta el 2 de noviembre hay 193 archivos diarios de IERSE. (3) Un flujo incremental declara 35 pasos con sus entradas y salidas, unidos por 92 dependencias, y rehace solo lo que cambia según el contenido (hash) de cada archivo. (4) Antes de publicar, una revisión automática con 10 controles busca secretos, datos personales, cifras desactualizadas y recomendaciones en voz de la universidad. Después, un revisor independiente lee el cambio. (5) La gobernanza incluye un comité de agentes de inteligencia artificial con papeles separados, reglas de privacidad y licencias por fuente. Lo pendiente está en 81 issues abiertos, 35 de ellos de prioridad P1. Los principales riesgos son tres: la recolección de IERSE depende de una sola máquina, la base del servidor no tiene respaldo externo y la licencia sin obras derivadas de la lluvia de IERSE choca con la publicación abierta de modelos.

Palabras clave: datos abiertos; reproducibilidad; flujo incremental; gestión de emergencias; gobernanza de datos; protección de datos personales; Galápagos.

Advertencia. Este informe describe una **infraestructura propia**, no un sistema oficial de información ni de alerta. Los productos que sirve (capas modeladas, nivel preliminar de inundación, estudios) son **modelos propios, no datos oficiales**. Por regla del repositorio, no se publican los servicios (endpoints) de las fuentes meteorológicas, ni las direcciones, la configuración o las credenciales de los servidores. El trabajo lo preparó un equipo asistido por agentes de inteligencia artificial, sin revisión profesional externa, y no expresa una posición institucional de la USFQ. Los datos de terceros conservan su licencia (sección 3.10).

© 2026 Universidad San Francisco de Quito (USFQ). Texto, figuras y modelos propios bajo licencia **CC BY 4.0**; el código, bajo Apache 2.0 con aviso de atribución (archivo `NOTICE`). Toda reutilización o publicación que use este material debe citar: Maya, J. (2026). *Infraestructura abierta de datos para una emergencia: recolección, flujo reproducible y gobernanza*. SOS Galápagos · Informe técnico 2026-10. Universidad San Francisco de Quito (USFQ). Los datos de terceros conservan sus licencias (ver `LICENCIA-DATOS.md`).

1. Introducción

En una emergencia los datos llegan por muchos canales y cambian cada hora: capas oficiales que hay que depurar, estaciones que transmiten cada cinco minutos, modelos que se rehacen cuando aparece un dato nuevo, textos que se corrigen. Si nadie gobierna ese flujo, aparecen cifras distintas para lo mismo, archivos editados a mano que nadie sabe regenerar y, sobre todo, datos personales o credenciales publicados por error.

SOS Galápagos montó su infraestructura de datos entre el 31 de octubre y el 4 de noviembre de 2026. La coordinó USFQ Galápagos y la escribió en buena parte un comité de agentes de IA. Todo vive en un repositorio público con tres salidas web: */mapas* (visor y descargas de capas), */estudios* (informes técnicos en web) y */clima* (panel en vivo). Los principios de partida son los de la investigación reproducible (Sandve et al., 2013; Wilson et al., 2017) y los de datos FAIR (Wilkinson et al., 2016). Se aplicaron con dos restricciones propias de la emergencia: había que trabajar en horas y no se podía exponer información sensible.

Este informe describe la infraestructura como un conjunto de datos. Explica de dónde salen los datos, cómo se guardan y procesan, cómo se revisan antes de publicarse y qué reglas los gobiernan. No evalúa los modelos: eso lo hacen los demás informes de la serie, por ejemplo el Informe técnico 2026-07 (Maya, 2026) para la alerta por lluvia.

2. Componentes y registros de datos

2.1 *Visión general*

La figura 1 resume la infraestructura en dos carriles:

- **Operación en vivo.** El recolector consulta las fuentes, guarda en SQLite y publica un panel con datos agregados.
- **Análisis reproducible.** El repositorio guarda los crudos, los scripts y las salidas generadas, y desde él se publican los mapas y los estudios.

El repositorio separa tres tipos de archivo (tabla 1). Cada archivo generado sale de un único script, y nunca se edita a mano.

Tabla 1. Tipos de archivo del repositorio y regla que los gobierna (`CONTRIBUIR.md`, §1).

Tipo	Ejemplos	Regla
Fuente (se edita a mano)	scripts, manifiestos, textos de los estudios, código del recolector, documentación	se cambia en una rama y entra por *pull request*
Crudo externo (se descarga)	capas oficiales en `geodatos/descargas/`; crudos de clima en `clima/datos/<fuente>/crudos/`	las capas oficiales crudas no van a git (pesan ≈ 400 MB y traen datos personales); los crudos de clima sí, y nunca se modifican
Generado (lo escribe un script)	capas finales, paquete del mapa, figuras, PDF, tablas consolidadas	nunca se edita a mano; ante un conflicto se toma la versión de `main` y se vuelve a correr el script

2.2 *Fuentes meteorológicas*

La tabla 2 resume las fuentes que entran al recolector. Solo se nombran: sus servicios de origen viven en una carpeta privada que no se versiona, y en el servidor, en la configuración del servicio.

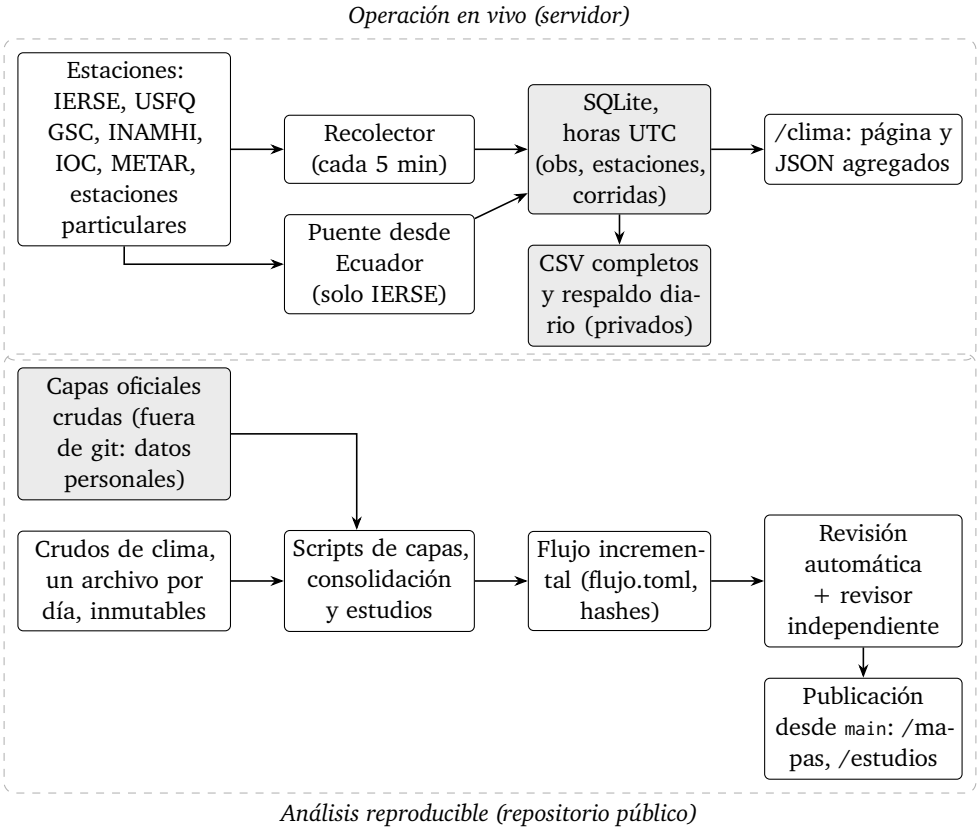


Figura 1. Arquitectura de la infraestructura de datos de SOS Galápagos. En gris, lo que no se publica. No se muestran direcciones, servicios de las fuentes ni configuración de los servidores.

2.3 *Registros guardados en el repositorio*

- **Crudos de IERSE-WSN**, en `clima/datos/ierse-wsn/crudos/AAAA-MM/AAAA-MM-DD.csv.gz`, tal como los entrega el servidor de origen (formato largo). Son 193 archivos diarios, del 23 de abril al 2 de noviembre de 2026, y ocupan 4,0 MB comprimidos. A partir de ellos se regeneran la serie de 5 min, la horaria y la diaria. La diaria incluye un porcentaje de cobertura (figura 2).
- **Historial horario del INAMHI** del 16 de octubre al 2 de noviembre (`clima/datos/inamhi/historial/`). Se archivó porque la fuente borra lo que tiene más de 90 días: si no se guarda, es irrecuperable.
- **Series diarias de la FCD** de Puerto Ayora (desde 1965) y Bellavista, y **series horarias del UHSLC** de nivel del mar.
- **Capas geográficas** depuradas (`geodatos/capas/`), el paquete del mapa (`geodatos/export/`) y el entregable `mapas-galapagos/`, todo en EPSG:4326.

La base SQLite del servidor no está en el repositorio: las bases (`*.db`) están excluidas de git.

3. Métodos

3.1 *Recolector*

El recolector es un programa en Python que un temporizador del sistema ejecuta cada 5 minutos. Cada fuente tiene su propia función, que convierte la hora de origen a UTC y escribe en tres tablas:

- `obs`: una fila por fuente, estación, variable y hora (ISO 8601 en UTC), con clave primaria compuesta. Repetir una consulta no duplica datos.
- `estaciones`: los metadatos de cada estación.

Tabla 2. Fuentes meteorológicas y oceanográficas del recolector. Hora de origen tal como la marca la fuente; en la base todo se guarda en UTC.

Fuente	Estaciones	Paso	Hora de origen
IERSE-WSN	4 en Santa Cruz (Cerro Crocker, Santa Rosa, Los Guayabillos, Militar)	≈ 5 min	UTC−6
USFQ GSC	4 en San Cristóbal (El Junco, Cerro Alto, El Mirador, Merceditas)	5 min	UTC−5 (aunque marque «Z»)
INAMHI	M0191 Puerto Ayora, M0221 Puerto Baquerizo; respaldo horario de 90 días	5 min / 1 h	UTC−5
IOC	mareógrafos de Puerto Ayora y Baltra	5 min	UTC
METAR	aeropuertos de Baltra y San Cristóbal	horario	UTC
Estaciones particulares	WeatherLink en Puerto Ayora y Tempest en Punta Estrada	5 min	UTC
Modelos	nivel del mar y pronóstico de lluvia (Open-Meteo)	horario	según consulta

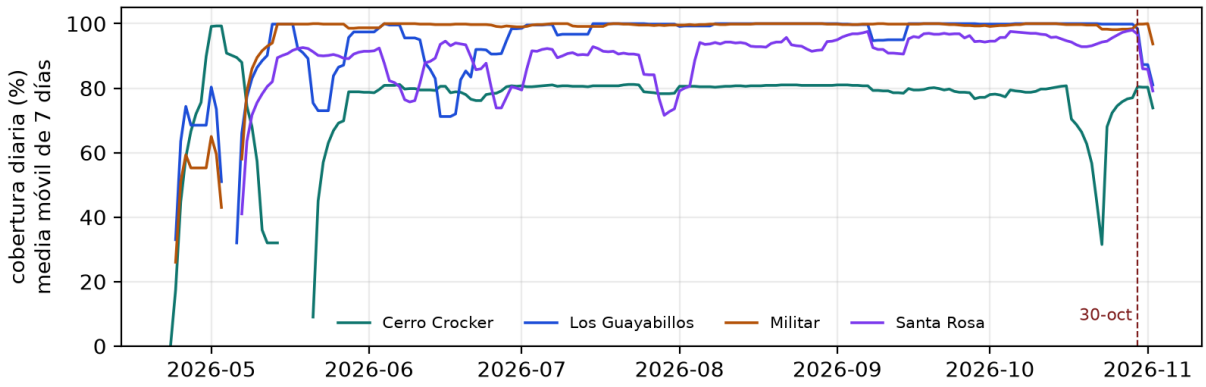


Figura 2. Cobertura diaria de las cuatro estaciones IERSE-WSN (porcentaje de los registros esperados cada 5 min, media móvil de 7 días), calculada desde las tablas consolidadas. Los huecos son días sin ningún registro. Cuando una estación no transmite, la lluvia de ese tramo no se mide: los totales de esos días son mínimos.

- `corridas`: una fila por consulta, con su hora, la fuente, si tuvo éxito, el número de registros, la duración y el error, si lo hubo.

Una fuente caída no detiene a las demás: el error queda registrado en `corridas` y la corrida sigue.

La tabla `corridas` tiene además un uso operativo. Permite distinguir si una estación calló o si falló la recolección propia, y la regla de alerta solo trata como «silencio en alerta» el primer caso (Maya, 2026).

Para el INAMHI, las filas horarias de respaldo se guardan a la mitad de la hora y solo en las horas sin datos de 5 min. Así un corte se rellena sin duplicar lluvia. Las horas se guardan siempre en UTC. Galápagos está en UTC−6, pero INAMHI y GSC marcan la hora continental (UTC−5) aunque digan «Z». Esa diferencia se comprobó con la hora actual y con el ciclo de la radiación solar. Un error de una hora en esta conversión movería todos los avisos.

3.2 *Puente de IERSE*

El servidor está fuera de Ecuador y el servicio de IERSE no le responde. Por eso, una máquina en Ecuador ejecuta cada 5 minutos el mismo recolector, solo para IERSE, sobre una base local. Después envía al servidor las filas nuevas por SSH, desde el último envío correcto más una hora de margen, con un mínimo de 2 h y un máximo de 72 h.

La llave del puente solo puede ejecutar una orden en el servidor: recibir filas. El receptor valida cada fila antes de guardarla. Solo acepta datos de IERSE, con identificadores, horas y valores bien formados, y sin caracteres que puedan inyectar contenido en la página. Si la llave se filtrara, no serviría para falsear la lluvia de otras fuentes.

Si la máquina duerme o se apaga, IERSE deja de actualizarse; al volver, recupera hasta 3 días.

3.3 *Publicación del panel de clima*

El recolector exporta un pequeño conjunto de JSON agregados para la página. El servidor web solo expone esa página y esos archivos: no hay descargas ni enlaces a las fuentes, y la página no se indexa. Los CSV mensuales completos se escriben cada hora en una carpeta privada, y la base se copia una vez al día. Las copias se conservan 14 días en el mismo servidor.

3.4 *Crudos inmutables y consolidación*

Los scripts de `clima/scripts/` bajan los días que faltan y los guardan sin correcciones. Los días con más de 2 días de antigüedad se consideran cerrados y no se vuelven a pedir; hoy y ayer se piden en cada corrida, porque las estaciones transmiten con retraso. Un día se puede rehacer de forma explícita.

Los filtros de calidad no tocan nunca el crudo: se aplican en la consolidación o en el análisis. Así, un error de filtrado se corrige volviendo a correr un script, sin perder el dato original.

3.5 *Flujo incremental*

Los estudios y las capas de estudios de */mapas* se rehacen con un flujo incremental (`geodatos/flujo.toml` y `geodatos/scripts/flujo.py`), en la tradición de `make` (Feldman, 1979) y de los gestores de flujos científicos (Köster y Rahmann, 2012).

Declaración. Cada paso p declara:

- su script y sus comandos;
- un conjunto de patrones de entrada E_p (con comodines y grupos con nombre) y de salida S_p;
- los demás scripts que importa;
- marcas opcionales: *pesado* (modelo 2D), *red* (baja datos), *manual* o *siempre* (controles).

Grafo. Un paso p depende de otro q si lee algo que q escribe:

$$q \to p \iff \operatorname{arch}(E_p \cup C_p) \cap \operatorname{arch}(S_q) \neq \varnothing, \tag{1}$$

donde C_p son los scripts del paso y $\operatorname{arch}(\cdot)$ son los archivos que casan con los patrones. Cuando un patrón aún no tiene archivos, se compara por la forma del patrón. El orden de ejecución es un orden topológico del grafo (Kahn, 1962), y un ciclo detiene el flujo con un mensaje.

Qué se rehace. Para cada paso se guarda la huella de su última corrida correcta: el hash BLAKE2b del contenido de cada entrada y de cada script, y una firma de la propia declaración. Un paso se rehace en cinco casos:

- cambió el contenido de una entrada;

- apareció o desapareció un archivo de entrada;
- falta una salida;
- cambió su declaración;
- se rehace un paso del que depende.

El hash se recalcula solo si cambian el tamaño o la fecha del archivo. Que se mire el contenido y no la fecha evita rehacer por un archivo que solo se copió.

Uso. El modo `–seco` lista qué se rehace y por qué, sin ejecutar nada. Con `–cambio RUTA` responde «¿qué se rehace si cambia este archivo?». Los pasos pesados, los que usan red y los manuales solo corren si se piden de forma explícita. Si el flujo falla en un paso, conserva el estado de los pasos que sí terminaron. Este modelo de dependencias se parece al de los sistemas de construcción con verificación por contenido (Mokhov et al., 2018). La figura 3 dibuja la reducción transitiva del grafo (Aho et al., 1972).

3.6 *Revisión antes de publicar*

`geodatos/scripts/revisar_publicacion.py` revisa el sitio generado y las fuentes versionadas. Si encuentra un error, la publicación se detiene (tabla 3). El control de secretos lee los valores privados de las fuentes para buscarlos en lo publicado y en lo versionado, pero nunca los imprime.

El control de datos personales busca correos, teléfonos con formato ecuatoriano y números de cédula que pasan el dígito verificador. También busca, en las descargas, campos con nombres de contacto (teléfono, correo, propietario, representante…). El control de cifras compara una lista de cifras clave de los textos con los datos de los que salen; si los datos cambian y el texto no, la revisión falla.

Tabla 3. Controles de la revisión automática (`revisar_publicacion.py`) y lo que queda para el revisor humano o agente (`geodatos/estudios/PUBLICAR.md`).

Control	Qué comprueba
1. Frescura	el sitio es más nuevo que sus textos, figuras y pendientes
2. Enlaces	enlaces internos, anclas, imágenes, capas del mapa y vista 3D (externos, a pedido)
3. Secretos	ni servicios de origen ni identificadores o credenciales de las fuentes meteorológicas
4. Palabras	«refugio», nunca «albergue»; «preliminar» solo en la etiqueta
5. Voz	sin recomendaciones en voz de la universidad
6. Datos personales	correos, teléfonos, cédulas y campos de contacto en páginas y descargas
7. Pie	responsable y etiqueta «Datos preliminares» en cada página
8. Cifras	las cifras clave de los textos coinciden con los datos
9. Pendientes	la caché de issues y las páginas de pendientes coinciden
10. Git	lo publicado corresponde a un commit (error en modo estricto)
Revisor	que cada cifra nueva salga de un dato; conclusiones y confianza; tono; modelo frente a dato oficial; figuras, mapa y 3D en el navegador

La publicación solo se hace desde la rama `main`, con el árbol limpio y con un único script (`servidores/publicar.sh`), que deja en el servidor un archivo con el commit publicado. Después de publicar, el modo `–produccion` descarga cada página y la compara con la versión local.

3.7 *Comité de agentes de IA y revisión independiente*

Los estudios los elaboró un sistema de IA (Claude, de Anthropic) organizado como comité de agentes con papeles separados:

- un asesor principal de hidrología e hidráulica;

- especialistas en meteorología, gestión del riesgo de desastres y planificación urbana y drenaje;
- un hidrólogo dedicado a San Cristóbal.

Un agente coordinador integra el trabajo. Las discrepancias se resolvieron de forma explícita y quedaron escritas. Algunos ejemplos:

- el volumen del vaso de La Cascada (55 000 frente a 125 000 m³);
- el tiempo de concentración;
- el huso de los datos de modelos (UTC−5 frente a UTC−6);
- cifras sin fuente, que se retiraron.

Un revisor científico independiente revisó la versión de La Cascada.

`PUBLICAR.md` formaliza cinco papeles: responsable, asesor de producción, especialistas temáticos, revisor independiente y revisión automática. Solo el responsable publica. El revisor no puede ser quien escribió el cambio, y su visto bueno queda en el commit con una línea `Revisado-por`.

Las sesiones de agentes trabajan en paralelo, cada una en su rama y en su propia copia del repositorio (*worktree*). Siguen reglas duras escritas en `AGENTS.md`:

- no subir capas oficiales crudas, credenciales ni bases de datos;
- no publicar servicios de las fuentes;
- depurar los datos personales en el script;
- distinguir modelo de dato oficial;
- no editar archivos generados;
- no desplegar sin pedido.

Esta misma serie de informes se redactó así, con varias sesiones en paralelo sobre carpetas separadas.

3.8 *Gobernanza: issues, prioridades y dueños*

Lo pendiente vive solo como issues del repositorio, con una prioridad y un tipo:

- **prioridad:** P1 (cambia decisiones de esta emergencia), P2 o P3;
- **tipo:** datos faltantes, más resolución, procesos, plataforma o gobernanza.

Las páginas de pendientes de */estudios* se generan desde esos issues, sin los de plataforma, y nunca se editan a mano. Cada carpeta tiene un dominio dueño: capas base, publicación de mapas, estudios, clima, entregable o servidores. Los archivos que toca casi todo el mundo (el manifiesto de capas, el índice de estudios y el README) se editan solo por bloque propio.

3.9 *Protocolo de datos personales*

Las capas oficiales de la SNGR y del MSP traen nombres y teléfonos de responsables de refugios y de fuentes de eventos. El protocolo tiene cuatro capas:

1. las descargas crudas no entran en git;
2. el script que produce cada capa copia solo una lista explícita de campos (lista blanca, en `07_oficiales.py`), así que un campo nuevo de la fuente no se publica por omisión;
3. las descripciones libres de los eventos de la SNGR, que traen nombres de personas afectadas, no se publican;
4. la revisión automática busca contactos en todo lo que se publica.

Nunca se nombra a personas afectadas. Las estaciones de particulares se presentan como «estación particular», salvo autorización expresa del titular. La población se publica solo de forma agregada. El protocolo formal frente a la Ley Orgánica de Protección de Datos Personales (Asamblea Nacional del Ecuador, 2021) sigue abierto (#48). Las guías de responsabilidad de datos en la acción humanitaria (Inter-Agency Standing Committee, 2021) son un marco de referencia para cerrarlo.

3.10 *Licencias por fuente*

El código propio se publica bajo Apache 2.0, con un aviso de atribución obligatorio. Los textos, las figuras, las capas y los resultados de los modelos propios se publican bajo CC BY 4.0, con atribución a la USFQ. Los datos de terceros conservan su licencia, y si esa licencia es más restrictiva, prevalece (tabla 4).

Tabla 4. Licencias de las fuentes de terceros y su efecto en lo derivado (`LICENCIA-DATOS.md`, `mapas-galapagos/documentacion/03-fuentes-y-licencias.md`).

Fuente	Licencia	Efecto en lo derivado
OpenStreetMap	ODbL 1.0	las bases derivadas se publican bajo ODbL
Copernicus GLO-30	libre con atribución	texto de atribución fijo
Google Open Buildings v3	CC BY 4.0 (u ODbL)	atribución
IGM, CGREG, SNGR, INOCAR, INEC, MSP, MINEDUC, CONALI	información pública con cita	citar a la institución; confirmar para usos formales
IERSE-WSN (Orellana-Samaniego et al., 2023)	CC BY-NC-ND 4.0	sin uso comercial ni obras derivadas: los modelos con su lluvia requieren permiso del titular
FCD, series climáticas	CC BY-NC-SA	lo derivado (p. ej., curvas IDF), no comercial y con la misma licencia
USFQ GSC	no declarada (#46)	sus series no se redistribuyen
Proyecto DARWIN (U. de Marburgo)	acuerdo que prohíbe redistribuir (#76)	solo metadatos y DOI
GAR (TU Berlín), Open-Meteo	CC BY 4.0	atribución

4. Resultados: estado de la infraestructura

4.1 *El grafo del flujo*

El 4 de noviembre, `flujo.toml` declara 35 pasos que usan 31 scripts distintos (tabla 5, figura 3). Por tipo:

- 25 pasos normales;
- 7 pesados: modelos 2D de Santa Cruz y San Cristóbal, sensibilidad, tormentas sintéticas, sus figuras y curvas IDF. Uno de ellos, el contraste con ANUGA, es además manual;
- 2 que bajan datos de internet: lluvia de modelos e issues;
- 1 control que corre siempre: la revisión.

Las 92 dependencias se reducen a 54 aristas sin las transitivas, repartidas en 8 niveles. El paso que genera el sitio web depende directamente de 28 pasos.

Tabla 5. Alcance de cambios típicos: pasos que leen directamente el archivo y total de pasos que se rehacen al propagar el cambio por el grafo (de 35).

Archivo que cambia	Directos	Total	Pesados
Serie de 5 min de IERSE (`serie_5min.csv.gz`)	6	27	7
DEM de Santa Cruz	12	22	6
Serie diaria de la FCD (Bellavista)	2	4	1
Caché de issues (`pendientes.json`)	1	3	0
Un texto del estudio de Santa Cruz	1	2	0

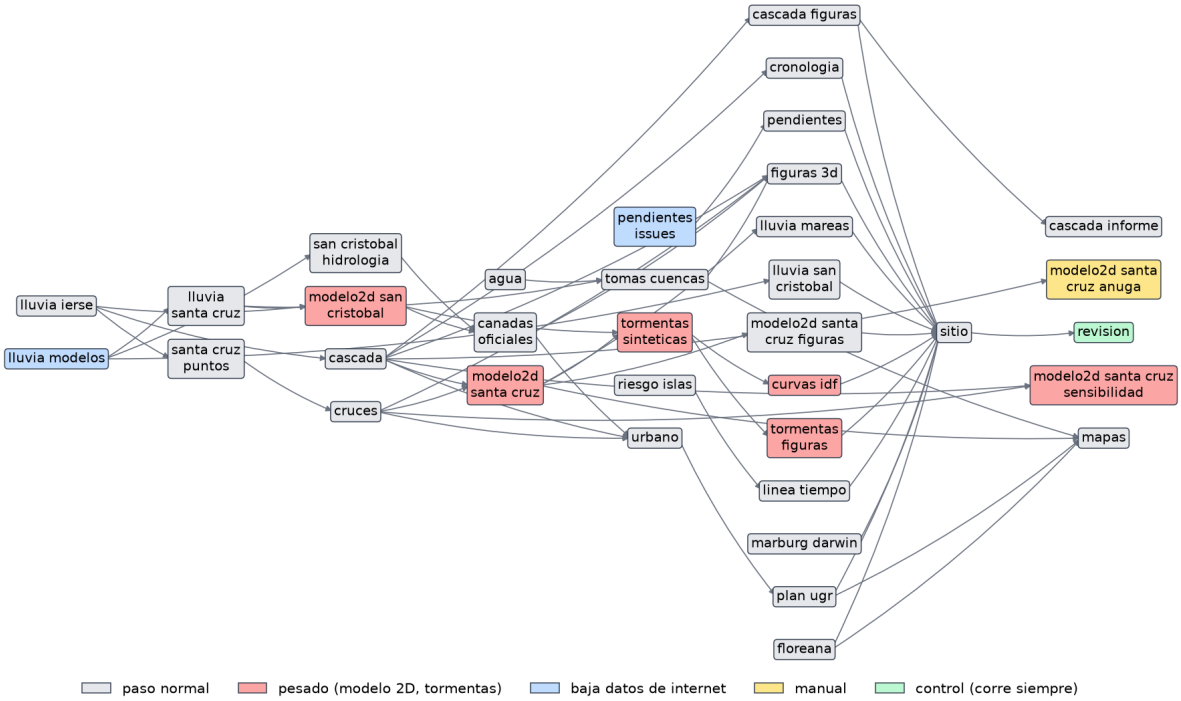


Figura 3. Grafo del flujo incremental de los estudios (reducción transitiva: 54 de 92 dependencias). Cada paso queda a la izquierda del primero que usa sus salidas. Generado desde `geodatos/flujo.toml` con las funciones de `flujo.py`, sin ejecutar ningún paso.

Una nueva descarga de lluvia de IERSE alcanza 27 de los 35 pasos, entre ellos los 7 pesados. Eso cuantifica el costo de rehacer los estudios cada vez que llega un día nuevo, y justifica que los pesados solo corran a pedido. Un texto corregido, en cambio, solo regenera el sitio y vuelve a pasar la revisión.

4.2 *Crudos y cobertura*

Los crudos de IERSE cubren 193 días: 8 de abril, entre 30 y 31 por mes de mayo a octubre, y 2 de noviembre. La cobertura media diaria es:

- Militar: 98,2 % (184 días con datos);
- Los Guayabillos: 95,6 % (181 días);
- Santa Rosa: 90,3 % (180 días);
- Cerro Crocker: 78,4 % (174 días).

Cerro Crocker se queda en ≈ 80 % desde junio y su pluviómetro parece obstruido desde agosto (figura 2; #56). El 30-oct, las estaciones dejaron de transmitir a las 21:22–21:25 y volvieron unas 21 h después. Esa lluvia no está en los crudos, y su recuperación es un pendiente P1 (#62).

4.3 *Pendientes de gobernanza y plataforma*

El 4 de noviembre hay 81 issues, todos abiertos: 35 de prioridad P1, 36 de P2 y 10 de P3. La tabla 6 resume los de gobernanza y plataforma que tocan esta infraestructura.

5. Discusión y limitaciones

Puntos únicos de falla. La infraestructura tiene tres:

- el puente de IERSE corre en una sola máquina personal: si se apaga más de 3 días, se pierde

Tabla 6. Issues de gobernanza y plataforma relacionados con la infraestructura (todos abiertos el 4-nov-2026).

Issue	Prioridad	Tema
#38	P1	respaldo de la base del clima fuera del servidor (hoy, copias locales de 14 días)
#39	P1	aviso si el recolector deja de correr
#45	P1	acuerdos de intercambio de datos con GAD, CGREG, DPNG, FCD, INAMHI, SNGR e INOCAR
#48	P1	protocolo de datos personales (LOPDP)
#49	P1	distinguir siempre dato oficial de modelo propio
#76	P1	series del proyecto DARWIN y permiso para publicar derivados
#36	P2	publicación automática desde `main`
#37	P2	validación automática en cada *pull request* (GeoJSON, EPSG:4326, datos personales, catálogo)
#46	P2	licencia de los datos del GSC
#47, #42	P2	metadatos y catálogo por capa (fuente, fecha, licencia, resolución, responsable)
#50	P2	licencia del código y de los datos derivados
#51	P2	equipo local (USFQ, GAD, CGREG) que mantenga los datos después de la emergencia
#43, #44	P3	tamaño del repositorio; capas heredadas que dicen «albergue»

lluvia;

- la base del servidor solo tiene copias en el mismo servidor (#38);
- nada avisa si el recolector deja de correr (#39).

Una caída de cualquiera de los tres en plena tormenta repetiría el problema del 30-oct, cuando los datos faltaron justo en el peor momento. La regla de alerta distingue el silencio de una estación del fallo propio, pero solo si la tabla de corridas existe y está al día.

El flujo es tan bueno como sus declaraciones. El grafo de dependencias sale de lo que cada paso *declara* leer y escribir. Si un script lee un archivo que no está declarado, el flujo no lo rehace cuando ese archivo cambia, y el resultado queda desactualizado sin aviso. La revisión de frescura solo mira las fuentes del sitio, no los datos intermedios. Además, el estado de las corridas es local, así que cada copia del repositorio empieza por dar por buenas las salidas versionadas (`-marcar`).

Reproducibilidad parcial. Cualquiera puede rehacer los estudios desde los crudos de clima y las capas versionadas. Las capas base, en cambio, se rehacen desde descargas que no están en git (≈ 400 MB, con datos personales), y algunas fuentes tienen servicios que cambian o datos que caducan: el INAMHI guarda solo 90 días. Archivar los crudos en cuanto llegan mitiga lo segundo. No hay, por ahora, un depósito con DOI de cada versión publicada.

Licencias que no encajan. El contenido propio se publica bajo CC BY 4.0, pero la lluvia de IERSE es CC BY-NC-ND, y casi todos los modelos de Santa Cruz la usan. Mientras no haya permiso escrito del titular, las salidas de esos modelos quedan sujetas a esa restricción. Algo parecido pasa con el GSC (licencia no declarada) y con DARWIN (redistribución prohibida). El issue #50 pide definir las licencias propias. En la práctica ya se adoptaron Apache 2.0 y CC BY 4.0, pero el issue sigue abierto.

Agentes de IA. El comité de agentes permitió tener en cuatro días estudios con cientos de cifras trazables a un script. A cambio:

- ningún estudio tiene revisión de profesionales habilitados ni visita de campo;

- el revisor independiente también es, en general, un agente;
- la línea `Revisado-por` que pide `PUBLICAR.md` no aparece todavía en el historial de esta rama de trabajo.

La revisión automática atrapa lo que un programa puede ver, como los secretos, los datos personales y las cifras clave. El tono, las conclusiones y la distinción entre modelo y dato oficial dependen del revisor.

Seguridad. No publicar servicios de las fuentes ni la configuración de los servidores reduce la superficie expuesta, pero no la elimina. El control de secretos busca valores conocidos; un secreto nuevo que no esté en la carpeta privada pasaría inadvertido. Si un secreto llega a un commit, la única corrección posible es limpiar el historial y cambiar la credencial.

6. Conclusiones y trabajo futuro

1. La infraestructura separa operación en vivo (recolector, SQLite en UTC, panel con datos agregados) y análisis reproducible (crudos inmutables, scripts, flujo incremental). Los separa por diseño, no solo por carpetas.
2. El flujo incremental hace explícitas las dependencias: 35 pasos y 92 dependencias. Así se sabe qué rehacer ante un dato nuevo; la lluvia de IERSE alcanza 27 pasos.
3. La revisión automática y el revisor independiente cubren riesgos distintos: lo que un programa puede verificar y lo que requiere juicio.
4. La privacidad se resuelve en el origen (lista blanca de campos, crudos fuera de git) y se verifica al publicar.
5. Los mayores riesgos abiertos son los puntos únicos de falla (#38, #39), los acuerdos y licencias de datos (#45, #46, #76) y la continuidad después de la emergencia (#51).

Trabajo pendiente (todo como issues):

- respaldo externo y monitoreo del recolector (#38, #39);
- validación en cada *pull request* y publicación automática desde `main` (#36, #37);
- catálogo de metadatos por capa (#42, #47);
- protocolo LOPDP (#48);
- acuerdos de datos y licencias pendientes (#45, #46, #50, #76);
- equipo local que mantenga la infraestructura (#51).

Disponibilidad de datos y código

Todo está en el repositorio público *mayait/sosgalapagos-datos*, salvo los servicios de origen, las credenciales y la configuración de los servidores:

- recolector: `clima/recolector/` (`recolector.py`, `fuentes_extra.py`); puente: `clima/puente/`; documentación: `clima/LEEME.md` y `servidores/README.md`;
- crudos y tablas: `clima/datos/` (`LEEME.md` con la forma de citar cada fuente);
- flujo: `geodatos/flujo.toml` y `geodatos/scripts/flujo.py`; revisión: `geodatos/scripts/revisar_publicacion.py` y `geodatos/estudios/PUBLICAR.md`;
- reglas: `AGENTS.md`, `CONTRIBUIR.md`, `LICENCIA-DATOS.md`, `CITATION.cff`;
- figuras 2 y 3 y cifras de la sección de resultados: `informes/2026-10-infraestructura/figuras.py`, que escribe `figuras/resumen.json`.

Este informe se compila con `informes/compilar.sh 2026-10-infraestructura`.

Referencias

Alfred V. Aho, Michael R. Garey, y Jeffrey D. Ullman. The transitive reduction of a directed graph. *SIAM Journal on Computing*, 1(2):131–137, 1972. doi: 10.1137/0201008.

Asamblea Nacional del Ecuador. Ley orgánica de protección de datos personales, 2021. Registro Oficial, Quinto Suplemento n.º 459, 26 de mayo de 2021; número y fecha por verificar.

Stuart I. Feldman. Make—a program for maintaining computer programs. *Software: Practice and Experience*, 9(4):255–265, 1979. doi: 10.1002/spe.4380090402.

Inter-Agency Standing Committee. Operational guidance on data responsibility in humanitarian action. Informe técnico, IASC, 2021. Datos de edición por completar.

Arthur B. Kahn. Topological sorting of large networks. *Communications of the ACM*, 5(11):558–562, 1962. doi: 10.1145/368996.369025.

Johannes Köster y Sven Rahmann. Snakemake—a scalable bioinformatics workflow engine. *Bioinformatics*, 28(19):2520–2522, 2012. doi: 10.1093/bioinformatics/bts480.

Julián Maya. Nivel preliminar de inundación por lluvia medida: la regla v0.2 de la alerta de SOS Galápagos. SOS Galápagos · Informe técnico 2026-07, Universidad San Francisco de Quito (USFQ), 2026. Borrador para discusión.

Andrey Mokhov, Neil Mitchell, y Simon Peyton Jones. Build systems à la carte. *Proceedings of the ACM on Programming Languages*, 2(ICFP):79, 2018. doi: 10.1145/3236774.

María L. Orellana-Samaniego, A. Cabrera-Lituma, D. Omar, Rolando Célleri, Jörg Bendix, y Daniela Ballari. Proyecto DARWIN. Versión 2023.1. Informe técnico, IERSE, Universidad del Azuay, Cuenca, 2023. Cita que pide la fuente para la red IERSE-WSN; nombres de pila de dos autores por completar.

Geir Kjetil Sandve, Anton Nekrutenko, James Taylor, y Eivind Hovig. Ten simple rules for reproducible computational research. *PLoS Computational Biology*, 9(10):e1003285, 2013. doi: 10.1371/journal.pcbi.1003285.

Mark D. Wilkinson, Michel Dumontier, IJsbrand Jan Aalbersberg, et al. The FAIR guiding principles for scientific data management and stewardship. *Scientific Data*, 3:160018, 2016. doi: 10.1038/sdata.2016.18.

Greg Wilson, Jennifer Bryan, Karen Cranston, Justin Kitzes, Lex Nederbragt, y Tracy K. Teal. Good enough practices in scientific computing. *PLoS Computational Biology*, 13(6):e1005510, 2017. doi: 10.1371/journal.pcbi.1005510.